

MATCH DAY

DATA ANALYSIS FIFA

1930-2022: HISTOIRE, PERFORMANCES ET PRÉDICTIBILITÉ
DES RÉSULTATS

BOOTCAMP
JUN 2026

LIORA FOOTBALL STADIUM
PARIS

KICK OFF
RENDU 1

LIORA 2026

JULIEN HUJDUS

Sommaire

Partie A — p.3

1

Comprendre le besoin

Objectif et questions

p.4

2

Exploration des CSV

Lignes, colonnes, types

p.8

3

Qualité des données

Manquantes, aberrantes

p.10

4

Nettoyage données

NaN, doublons, formats

p.12

5

Relations fichiers

Jointures entre fichiers

p.14

6

Base de travail

Dataframe propre final

p.15

7

Analyse EDA

Comparaison catégories

p.17

8

Réponses partie 1

5 questions répondues

p.27

9

Conclusions

Bilan et limites

p.29

Partie B — p.30

1

Modélisation données

Schéma en étoile, 5 tables Power BI

p.31

2

Classification problème

Objectifs et critères, problématique mélier

p.35

3

Conception rapports

Structure, interactions, 4 sous-thématiques

p.37

4

Interprétation résultats

Analyse, enseignements, visualisation

p.41

Conclusion — p.44

1

Difficultés rencontrées

Verrous techniques et scientifiques

p.45

2

Bilan

Contribution et résultats obtenus

p.47

3

Pour finir

Pistes d'amélioration, synthèse finale

p.48

PARTIE A

ANALYSE ET EXPLORATION DES DONNÉES

PARTIE 1

Comprendre le besoin

1.1 Objectif de l'analyse

L'idée de ce projet est de croiser cinq sources de données autour de la Coupe du Monde de football pour en tirer une lecture chiffrée, pas juste une liste de statistiques. Au-delà du côté « qui a gagné quand », nous voulions surtout regarder si la force réelle des équipes avant un tournoi (via le classement Elo et le classement FIFA), permettait vraiment d'anticiper les résultats, et vérifier si l'avantage du pays organisateur, dont on parle beaucoup, se retrouve dans les chiffres.

Ce rapport s'adresse avant tout au grand public passionné de football, pas à un public d'experts en statistiques : quelqu'un qui suit la Coupe du Monde, qui a ses idées reçues sur l'avantage du terrain ou sur les favoris, et qui a envie de voir si les chiffres confirment ou non ce qu'on pense généralement. C'est aussi pour ça que les graphiques et les explications sont pensés pour rester lisibles sans connaissances techniques particulières, plutôt que pour un public de data scientists.

Pour y arriver, nous avons suivi la démarche classique d'un projet data : comprendre le besoin, explorer les fichiers, vérifier la qualité des données, nettoyer ce qui doit l'être, relier les sources entre elles, construire une base de travail propre, puis analyser et répondre aux questions posées ici.

1.2 Les sources de données

Cinq fichiers sont utilisés, et ils n'ont pas grand-chose en commun à part le sujet :

- `world_cup.csv` (dataframe `wc`) : une ligne par édition du Mondial (22 lignes, de 1930 à 2022) — hôte, nombre d'équipes, champion, finaliste, meilleur buteur, affluence.
- `matches_1930_2022.csv` (dataframe `matches`) : le détail de chaque match joué depuis 1930 (964 matchs, 44 colonnes) — scores, xG, cartons, buteurs, arbitres, etc.
- `fifa_ranking_2022-10-06.csv` (dataframe `ranking`) : le classement officiel FIFA au 6 octobre 2022, juste avant le Mondial au Qatar (211 sélections).
- `teams.csv` (dataframe `teams`) : une table de correspondance entre 330 codes pays et leurs noms (avec parfois plusieurs orthographes possibles).
- `elo.csv` (dataframe `elo`) : l'historique année par année du classement Elo (un indicateur de force sportive utilisé en football depuis longtemps) pour chaque sélection, de 1901 à 2025 — presque 17 900 lignes.

Le vrai défi de ce projet n'est pas dans la quantité de données mais dans le fait que chaque fichier parle des pays à sa façon, et n'a pas le même niveau de détail temporel. Une bonne partie du travail, détaillée en Partie 5, a consisté à faire parler ces fichiers le même langage avant de pouvoir les croiser.

Pour la reproductibilité du projet, voici les chemins d'accès utilisés pour charger chaque source depuis Google Drive dans Google Colab :

Dataframe	Fichier	Chemin (path)
wc	world_cup.csv	/content/drive/MyDrive/Projet FIFA/Dataset/world_cup.csv
matches	matches_1930_2022.csv	/content/drive/MyDrive/Projet
ranking	fifa_ranking_2022-10-06.csv	/content/drive/MyDrive/Projet FIFA/Dataset/fifa_ranking_2022-
teams	teams.csv	/content/drive/MyDrive/Projet FIFA/Dataset/teams.csv
elo	elo.csv (regroupement de fichiers)	/content/drive/MyDrive/Projet FIFA/Dataset/elo

Le dossier "elo" regroupe l'ensemble des fichiers Elo bruts qui ont été fusionnés en un seul dataframe elo.csv lors du chargement.

1.3 Les questions à se poser

En partant du point de vue d'un fan de foot plutôt que d'un statisticien, nous nous sommes demandés quelles questions reviennent le plus souvent autour d'un match ou d'un tournoi : est-ce que jouer à domicile aide vraiment, est-ce que les meilleures équipes sur le papier gagnent effectivement, quelles nations ont écrit l'histoire de la compétition. Pour couvrir les cinq fichiers et arriver à des réponses concrètes (données en Partie 8), nous avons retenu cinq questions qui reprennent cette logique :

- Comment le format de la Coupe du Monde a évolué depuis 1930 ?
- Y a-t-il un vrai avantage à jouer à domicile, et cet avantage change-t-il pour le pays qui organise le tournoi ?
- Est-ce que la force sportive d'une équipe avant le tournoi (classement Elo ou classement FIFA) permet de prédire l'issue des matchs ?
- Comment les 211 sélections du classement FIFA se répartissent-elles entre les six confédérations continentales ?

Aucune de ces questions ne peut être traitée avec un seul fichier : la première demande wc, les deux suivantes demandent matches et wc, la quatrième demande de croiser matches avec elo et ranking, et la dernière repose sur ranking. C'est ce qui justifie tout le travail de mise en relation présenté dans les parties suivantes.

Avec mon groupe de travail, on s’est mis d’accord sur une question globale qui est: quels sont les éléments qui nous permettent de prédire qu’une équipe a plus de chance de gagner qu’une autre?

1.4 D'où viennent ces données ?

Les cinq fichiers utilisés ici correspondent à des types de données qu'on retrouve couramment en accès libre dans la communauté data, mais je n'ai pas de garantie formelle sur la licence exacte de chacun puisqu'ils m'ont été fournis directement pour ce projet, sans mention de source précise. Un dernier fichier permettra de travailler sur la valeur marchande des sélections.

Ce que je peux dire avec plus de certitude : le classement FIFA (ranking) reprend des chiffres que la FIFA publie elle-même publiquement sur son site, donc une donnée d'origine publique. Le fichier elo, avec sa structure par équipe et par année, correspond au format diffusé par le projet World Football Elo Ratings, qui met ses données à disposition en accès libre. Les fichiers world_cup et matches ressemblent aux jeux de données qu'on trouve sur des plateformes comme Kaggle, généralement compilés à partir de sources publiques par des contributeurs indépendants. Le fichier teams, enfin, est un simple référentiel de codes pays qui ne semble pas soumis à un droit de propriété particulier. Côté volumétrie, les cinq fichiers vont de 22 lignes (wc) à un peu moins de 18 000 lignes (elo après fusion de tous les fichiers en un seul et unique), pour un total d'une vingtaine de colonnes en moyenne par fichier ; le détail complet est donné en Partie 2.1.

PARTIE 2

Exploration des CSV

Avant de toucher à quoi que ce soit, nous avons commencé par regarder chaque fichier tel qu'il est : combien de lignes, combien de colonnes, quelles types de données dedans.

2.1 Lignes et colonnes

Dataframe	Fichier source	Lignes	Colonnes
wc	world_cup.csv	22	9
matches	matches_1930_2022.csv	964	44
ranking	fifa_ranking_2022-10-06.csv	211	7
teams	teams.csv	330	2
elo	elo.csv	17 884	14

Ce qui frappe tout de suite, c'est l'écart de volumétrie : elo.csv à lui seul contient dix-huit fois plus de lignes que tous les autres fichiers réunis. C'est logique puisqu'il donne une observation par équipe et par année sur plus d'un siècle, alors que wc.csv n'a qu'une ligne tous les quatre ans.

2.2 Vérifier les variables

En parcourant les colonnes de chaque fichier, on peut les regrouper par grandes familles.

wc — les infos d'une édition

Year, Host, Teams et Matches donnent le contexte de l'édition ; Champion, Runner-Up et TopScorrer sont du texte ; Attendance et AttendanceAvg sont les chiffres d'affluence.

matches — le détail d'un match

Les 44 colonnes couvrent plusieurs aspects : l'identité du match (équipes, année, tour, date, stade, hôte), le résultat (scores, xG), l'encadrement (sélectionneurs, capitaines, arbitre), et une longue série de colonnes très détaillées sur les événements du match (buteurs, cartons, penalties, tirs au but, remplaçants), stockées sous forme de texte listant les événements avec leur minute.

ranking — le classement FIFA

Nom de l'équipe, code à trois lettres, confédération, rang actuel et précédent, points actuels et précédents.

teams — la table de correspondance

Un code pays (colonne DN, par exemple « FR ») et le ou les noms associés (colonne Aden), parfois plusieurs alias pour un même pays.

elo — la force sportive année par année

Code pays, score Elo au 31 décembre, score et rang moyens sur l'année, nombre de matchs (total, à domicile, à l'extérieur, en terrain neutre), victoires, défaites, nuls, buts marqués et encaissés, année.

2.3 Les types de colonnes

Au chargement, la plupart des colonnes numériques sont déjà bien reconnues comme telles. Dans matches, sur les 44 colonnes, seules 8 sont numériques (scores, xG, année, affluence) ; toutes les autres sont du texte, y compris certaines colonnes qui contiennent en réalité des listes d'événements plutôt qu'une vraie valeur textuelle simple. La colonne Date, elle, est chargée comme du texte brut et devra être convertie en vraie date (datetime), ce qui est fait en Partie 4.

Dans wc, ranking et teams, le typage de base ne pose pas de problème. Dans elo, tout est propre à l'exception de la colonne team, qui comporte 37 valeurs manquantes alors qu'elle ne devrait jamais l'être. Ce point est expliqué dans la partie suivante.

2.4 Les variables les plus utiles, et les limites à garder en tête

Avec quatre questions différentes à traiter, toutes les colonnes ne se valent pas. Les plus utiles pour ce projet sont : Year et Host (pour situer chaque match dans son édition et repérer le pays organisateur), home_score/away_score (pour tout ce qui touche aux résultats), home_team/away_team une fois harmonisés (la clé qui permet de tout relier), elo_score_dec31 (la mesure de force sportive qui couvre tout l'historique), et association dans ranking (pour la répartition par confédération). Les dizaines de colonnes très détaillées de matches sur les buteurs, les cartons ou les tirs au but ne sont pas mobilisées dans cette version du projet, mais représentent une réserve d'analyse pour aller plus loin.

Ce qui rend ce jeu de données particulier, c'est surtout le mélange de granularités très différentes : une ligne par édition, une ligne par match, une photo de classement à un instant donné, et un historique annuel sur plus d'un siècle. C'est ce mélange qui permet de croiser une vision très fine (le match) avec une vision très large (l'évolution d'une nation sur 120 ans), mais c'est aussi ce qui demande le plus de travail de mise en cohérence, détaillé dans les parties 3 à 5.

Sur les limites : je reste dépendant de la qualité et de la couverture des fichiers fournis. Le classement FIFA n'existe qu'en une seule photo (octobre 2022), ce qui limite son usage à la seule édition 2022 ; certains pays ayant disparu politiquement n'ont pas d'équivalent dans les classements actuels ; et les colonnes d'événements très fines de matches sont trop parcellaires avant les années 1990 pour être exploitées sur l'ensemble de l'historique. Ces limites sont reprises plus en détail en Partie 10.2.

2.5 Détail des colonnes par DataFrame

DataFrame WC: les infos d'une édition

Colonne	Type	Exemple de contenu
Year	entier	2022 2018
Host	str	Qatar Russia
Teams	entier	32 24
Champion	str	Argentina France
Runner-Up	str	France Croatia
TopScorrer	str	Kylian Mbappé - 8 Harry Kane - 6
Attendance	entier	3404252 3031768
AttendanceAvg	entier	53191 47371
Matches	entier	64 52

DataFrame matches: le détail d'un match

Colonne	Type	Exemple de contenu
home_team	str	Argentina Croatia
away_team	str	France Morocco
home_score	entier	3 2
home_xg	décimal	3.3 0.7
home_penalty	décimal	4.0 3.0
away_score	entier	3 1
away_xg	décimal	2.2 1.2
away_penalty	décimal	2.0 4.0
home_manager	str	Lionel Scaloni Zlatko Dalić
home_captain	str	Lionel Messi Luka Modrić
away_manager	str	Didier Deschamps Hoalid Regragui
away_captain	str	Hugo Lloris Hakim Ziyech
Attendance	entier	88966 44137
Venue	str	Lusail Iconic Stadium, Lusail Khalifa International Stadium, Doha
Officials	str	Szymon Marciniak (Referee) · Paweł Sokolnicki (AR1) · Tomasz Listkiewicz (AR2) · Jemal El
Round	str	Final Third-place match
Date	str	2022-12-18 2022-12-17
Score	str	(4) 3–3 (2) 2–1
Referee	str	Szymon Marciniak Abdulrahman Ibrahim Al Jassim
Notes	str	Argentina won on penalty kicks following extra time Croatia won on penalty kicks followi
Host	str	Qatar Russia
Year	entier	2022 2018
home_goal	str	Ángel Di María · 36 Lionel Messi · 108 Joško Gvardiol · 7 Milos Ozčić · 42
away_goal	str	Kylian Mbappé · 81 Achraf Dari · 9
home_goal_long	str	['36’ 2:0 Ángel Di María Assist: Alexis Mac Allister' 1:0:0 ’ 2:2 Lionel Messi
away_goal_long	str	['81’ 2:2 Kylian Mbappé Assist: Marcus Thuram' 1:0:0 ’ 1:1 Achraf Dari'
home_own_goal	str	Nayef Aguerd (OG) · 40 Manuel Neuer (OG) · 70
away_own_goal	str	Enzo Fernández (OG) · 77 Fernandinho (OG) · 13
home_penalty_goal	str	Lionel Messi (P) · 23 Lionel Messi (P) · 34
away_penalty_goal	str	Kylian Mbappé (P) · 80 Kylian Mbappé (P) · 118 Lionel Messi (P) · 72
home_penalty_miss_long	str	['84’ 1:2 Harry Kane Penalty Miss'] ['21:0 ’ 0:0 Andrés Avellan Penalty saved by
away_penalty_miss_long	str	['39’ 0:0 Lionel Messi Penalty saved by Wojciech Szczęsny'] ['45:1:0 ’ 1:0
home_penalty_shootout_goal_long	str	['2 1:1 Lionel Messi', '4 2:1 Paulo Dybala', '6 2:1 Leandro Paredes', '8 4:2 Gonzalo Montiel
away_penalty_shootout_goal_long	str	['1 0:1 Kylian Mbappé', '7 3:2 Randal Kolo Muani'] ['4 2:1 Griezmann', '6 2:2 Pedri']
home_penalty_shootout_miss_long	str	['1 0:0 Virgil van Dijk', '3 0:1 Steven Berghuis'] ['5 2:0 Pedro Penedo']
away_penalty_shootout_miss_long	str	['3 1:1 Kingsley Coman', '5 2:1 Aurélien Tchouaméni'] ['2 1:0 Rodrygo', '8 4:2 Marquinhos
home_red_card	str	Paulo Bento · 90+11 Wayne Hennessey · 86
away_red_card	str	Michael Lang · 90+3 Steven Defour · 44

DataFrame ranking: le classement FIFA

Colonne	Type	Exemple de contenu
team	str	Brazil Belgium
team_code	str	BRA BEL
association	str	CONMEBOL UEFA
rank	entier	1 2
previous_rank	entier	1 2
points	décimal	1841.3 1816.71
previous_points	décimal	1837.56 1821.92

DataFrame Teams: la table de correspondance

Colonne	Type	Exemple de contenu
DN	str	AF AL
Aden	str	Afghanistan Albania

DataFrame elo: la force sportive année par année

Colonne	Type	Exemple de contenu
team	str	BT VI
elo_score_dec31	entier	614 617
elo_rank_avg	entier	219 206
elo_score_avg	entier	599 685
matches_total	entier	114 79
matches_home	entier	20 27
matches_away	entier	39 34
matches_neutral	entier	55 18
matches_wins	entier	11 9
matches_losses	entier	95 57
matches_draws	entier	8 13
goals_for	entier	65 50
goals_against	entier	414 296
year	entier	2025 2024

PARTIE 3

Vérifier la qualité des données

C'est l'étape où nous avons passé le plus de temps : c'est en creusant ligne par ligne que nous avons mis le doigt sur deux ou trois anomalies qu'on ne voit pas juste en lançant un `.isna().sum()` sans réfléchir.

3.1 Valeurs manquantes

Le nombre de valeurs manquantes est très inégal selon les fichiers. *wc* et *ranking* sont complets, sans aucune valeur manquante, *matches* en a beaucoup, mais *teams* et *elo* cachent une anomalie plus subtile.

Dans *matches*, un bon nombre de colonnes contiennent des valeurs manquantes, et ce sont presque toujours les colonnes qui décrivent des événements rares d'un match : but contre son camp, deuxième carton jaune, tir au but manqué, séance de tirs au but. Certaines de ces colonnes dépassent 95 % de valeurs manquantes. Ce n'est pas un problème de collecte : un NaN dans « but contre son camp » veut simplement dire qu'il n'y en a pas eu, ce qui est le cas dans la grande majorité des matchs. Ces valeurs manquantes ne doivent donc surtout pas être supprimées ou remplacées par une moyenne : elles portent une information en elles-mêmes. Elles sont donc remplacées par 0 mais ne seront, de toute façon, pas utilisées dans notre projet.

La vraie découverte est ailleurs, du côté de *teams.csv* et *elo.csv*. La Namibie utilise le code pays « NA ». Le souci, c'est que « NA » est justement l'une des valeurs que pandas considère par défaut comme une valeur manquante (au même titre qu'une cellule vide ou 'NaN'). Résultat : dans *teams.csv*, la ligne de la Namibie se retrouve avec un code manquant, et dans *elo.csv*, ce sont 37 lignes (une par année de présence de la Namibie dans la base) qui perdent leur code équipe de la même façon.

3.2 Doublons

Aucun des cinq fichiers ne contient de ligne strictement dupliquée. Nous avons aussi vérifié, une fois le nom de pays rattaché à chaque ligne de *elo*, qu'il n'existait pas deux lignes pour la même équipe la même année : c'était le cas, ce qui confirme qu'on peut utiliser (équipe, année) comme clé fiable pour la suite.

3.3 Formats incohérents

Plusieurs incohérences de format sont apparues en creusant *teams.csv* et *matches.csv*.

D'abord, dans *teams.csv*, près d'un tiers des lignes rassemblent plusieurs orthographes d'un même pays dans une seule cellule, séparées par une tabulation (par exemple « Antigua and Barbuda » et « Antigua & Barbuda » collés dans le même champ). Ce n'est pas gênant pour la lecture humaine, mais ça empêche toute jointure directe tant qu'on n'a pas extrait un nom « principal » par pays.

Ensuite, un même pays n'est pas toujours écrit pareil d'un fichier à l'autre : « United States » dans *matches* et *teams*, mais « USA » dans *ranking* ; « Iran » dans *teams*, mais « IR Iran » dans *matches* et *ranking* ; « Turkey » dans *teams*, mais « Türkiye » ailleurs ; « Ivory Coast » dans *teams*, mais « Côte d'Ivoire » dans *ranking*. Ce point est central pour la Partie 5 et je reviens dessus en détail dans la partie nettoyage.

Enfin, la colonne Champion de *world_cup.csv* indique « Germany » pour l'édition 1954, alors qu'à cette époque l'Allemagne était divisée en deux, et que c'est bien la République Fédérale d'Allemagne (RFA, notée « West Germany ») qui avait remporté le titre. Le fichier lui-même utilise d'ailleurs « West Germany » pour les éditions 1974 et 1990. C'est donc une incohérence de saisie propre au fichier, pas une question d'harmonisation entre fichiers.

3.4 Valeurs aberrantes

Nous avons regardé de près les valeurs extrêmes des variables numériques de matches, en particulier les scores et l'affluence.

Variable	Min	Max	Ce que ça donne
home_score	0	10	Hongrie 10 - 1 Salvador en 1982 : un score réel, pas une erreur de saisie.
Attendance	2 000	173 850	2 000 spectateurs pour Chili-France en 1930 (1ère édition, tout début du tournoi) ; 173 850 au Maracanã en 1950, un chiffre historique bien connu.

Aucune de ces valeurs n'a été corrigée ou retirée : ce sont des faits historiques vérifiables, pas des erreurs. C'est un bon rappel qu'une valeur loin de la moyenne n'est pas automatiquement une erreur, il faut toujours vérifier le contexte avant de toucher à quoi que ce soit.

PARTIE 4

Nettoyage des données

Cette partie met en pratique ce qui a été repéré en Partie 3.

4.1 Supprimer ou remplacer les NaN

Pour les colonnes d'événements rares de matches (but contre son camp, cartons, tirs au but), nous n'avons rien touché : les valeurs manquantes restent telles quelles puisqu'elles signifient simplement que l'événement n'a pas eu lieu. Pour l'anomalie de la Namibie, nous avons fait un remplacement ciblé plutôt qu'une suppression, puisque la vraie valeur est connue sans ambiguïté : dans teams.csv, le code manquant de la ligne « Namibia » est remis à « NA », et dans elo.csv, les 37 lignes concernées reçoivent le même correctif. Aucune autre ligne n'a été supprimée pour cause de valeur manquante dans les cinq fichiers : soit le fichier était déjà complet, soit la valeur manquante avait un sens ou a pu être restituée comme ici.

4.2 Supprimer les doublons

Comme aucun doublon n'a été détecté en Partie 3, il n'y avait rien à supprimer. Nous avons simplement gardé un contrôle systématique après chaque jointure pour nous assurer qu'aucun doublon n'apparaissait en cours de route.

4.3 Convertir les types

La seule vraie conversion de type concerne la colonne Date de matches, qui passe d'un texte au format AAAA-MM-JJ à un vrai type date. Les colonnes numériques (scores, affluence, points, rangs, scores Elo) étaient déjà bien typées dès le chargement.

4.4 Uniformiser les formats de date

Le format de date de matches est déjà homogène sur les 964 lignes : une vérification de la longueur des chaînes de caractères confirme qu'il n'y a qu'un seul format présent. Les fichiers wc et elo, eux, ne donnent que l'année sous forme de nombre entier, donc sans ambiguïté possible. Il n'y avait donc rien de plus à uniformiser au-delà de la conversion vue au point précédent.

4.5 Harmoniser les noms des catégories

C'est le plus gros morceau du nettoyage, parce que toutes les jointures de la Partie 5 en dépendent. Trois façons différentes d'écrire les noms de pays coexistent dans les cinq fichiers (celle de matches, celle de teams/elo, celle de ranking), et je devais en choisir une comme référence : nous avons pris celle de ranking, puisque c'est le référentiel FIFA le plus récent et le plus officiel, et avons construit une correspondance vers cette orthographe pour chaque cas où les fichiers divergent.

Pour les pays qui ont simplement changé d'orthographe ou de nom sans changement de frontière (États-Unis, Iran, Corée du Nord/Sud, Turquie, Côte d'Ivoire, Chine, Cap-Vert, Taïwan et une douzaine d'autres cas plus rares), la correspondance est directe et sans ambiguïté.

Le cas plus délicat concerne les pays qui n'existent plus tels quels : URSS, Tchécoslovaquie, RDA, Yougoslavie (RFY puis Serbie-Monténégro), Indes néerlandaises. Ces sélections n'ont pas d'équivalent unique dans le classement FIFA actuel puisque le pays a disparu. L'URSS, par exemple, a donné naissance à quinze fédérations distinctes, et la Russie n'en est qu'une parmi d'autres. Plutôt que de forcer un rattachement arbitraire (URSS vers Russie, par exemple, ce qui ignorerait l'Ukraine ou la Géorgie), nous avons choisi de laisser ces équipes sans correspondance vers le classement FIFA actuel. Elles restent bien sûr présentes dans les analyses historiques qui n'ont pas besoin de ce classement.

À côté de ce dictionnaire de correspondance, nous avons aussi corrigé directement dans *wc* l'incohérence du champion 1954, en remplaçant « Germany » par « West Germany » pour rester cohérent avec le reste du fichier.

Enfin, pour transformer les codes à deux lettres de *elo.csv* en vrais noms de pays, nous nous sommes appuyés sur *teams.csv* comme table de passage, en ne gardant que le premier alias de chaque cellule Aden comme nom « principal » du pays. Le résultat de tout ce travail se mesure directement en Partie 5 : la jointure entre *matches* et *elo* retrouve une correspondance pour 98,3 % des matchs, les quelques pourcents restants étant justement les pays disparus laissés de côté volontairement, ce qui confirme que la démarche tient la route.

4.6 Transformations et création de variables

Nous n'avons appliqué aucune normalisation ni standardisation aux données numériques. Ça n'aurait pas eu de sens ici : les scores Elo sont déjà construits pour être comparables entre équipes et dans le temps (c'est tout l'intérêt de cet indicateur), les buts marqués sont des comptages directement interprétables, et les rangs FIFA sont des positions dans un classement, pas des valeurs à mettre à l'échelle.

En revanche, nous avons créé plusieurs variables dérivées pour pouvoir répondre aux questions posées. Parmi elles : *year_ref* (l'année Y-1 utilisée pour aller chercher le bon score Elo avant chaque tournoi), *diff_elo* (l'écart de score Elo entre les deux équipes d'un match), les indicateurs *home_favori* et *home_gagne* (pour savoir si l'équipe favorite au sens Elo a effectivement gagné), une catégorie résumant le résultat du pays hôte (victoire / nul / défaite), ainsi que les colonnes *canon* et *Aden_principal* construites pendant le nettoyage pour disposer d'un nom de pays unique et exploitable. Ce sont ces variables construites, plus que les colonnes brutes, qui portent l'essentiel de l'analyse des Parties 7 et 8.

PARTIE 5

Relations entre les fichiers

5.1 Analyser les colonnes communes

Il n'y a pas d'identifiant technique commun entre les cinq fichiers : toutes les jointures reposent sur l'année et/ou le nom du pays, qu'il a fallu harmoniser au préalable comme expliqué en Partie 4. Le schéma retenu s'organise autour de quatre jointures :

Jointure	Clé(s)	Ce que ça apporte
wc ↔ matches	Year	Le contexte de l'édition (nombre d'équipes, champion) sur chaque match.
teams ↔ elo	code pays	La traduction des codes de elo.csv en noms de pays exploitables.
matches ↔ elo	pays + année N-1	La force Elo des deux équipes juste avant le tournoi.
matches ↔ ranking	pays (édition 2022 uniquement)	Le rang FIFA des deux équipes, pour comparer avec les résultats.

Un point mérite d'être expliqué : pourquoi utiliser deux indicateurs de force différents (elo et ranking) plutôt qu'un seul ? Le fichier ranking est une photo prise à un instant T, le 6 octobre 2022 : il n'a de sens que rapproché des matchs de cette même édition, pas de ceux de 1958. Le fichier elo, lui, couvre chaque année depuis 1901, ce qui permet de reconstituer la force de chaque équipe à l'approche de chacune des 22 éditions, et donc de mener l'analyse sur l'ensemble de l'historique plutôt que sur le seul dernier Mondial. C'est un des vrais apports du cinquième fichier par rapport à une version du projet qui se serait arrêtée aux quatre premiers.

Pour aligner elo avec matches dans le temps, j'ai choisi de prendre, pour un Mondial disputé en année Y, le score Elo de chaque équipe au 31 décembre de l'année Y-1, c'est-à-dire la dernière valeur connue avant le début du tournoi.

5.2 Réaliser les jointures

La première jointure, entre *matches* et *wc* sur l'année, se passe sans accroc : les 964 matchs trouvent tous une édition correspondante, sans aucune perte.

La deuxième, entre *matches* et *elo* (en passant par *teams* pour traduire les codes en noms de pays), est la plus intéressante à commenter. Sur les 964 matchs, 948 retrouvent un score Elo pour les deux équipes, soit 98,3 %. Les 16 matchs qui ne trouvent pas de correspondance concernent uniquement l'URSS, la RDA et la RFY, exactement les pays disparus laissés volontairement de côté lors de l'harmonisation des noms. Ce taux très élevé confirme que le travail fait en amont sur les noms de pays a porté ses fruits ; sans lui, la correspondance native entre les orthographes de matches et les codes de elo aurait été bien plus faible.

La troisième jointure, entre les seuls matchs de 2022 et le classement FIFA, fonctionne également sans perte : les 32 équipes qualifiées pour ce Mondial figurent toutes dans le classement d'octobre 2022, ce qui est logique puisque ce fichier couvre l'ensemble des sélections membres de la FIFA à cette date.

PARTIE 6

Construire une base de travail après les jointures

À partir des jointures de la Partie 5, nous avons construit deux dataframes de travail, chacun répondant à un usage différent.

6.1 base_matches_elo — la base principale (1930-2022)

Cette base rassemble, pour chacun des 964 matchs, le contexte de l'édition (issu de wc) et la force Elo des deux équipes juste avant le tournoi. C'est elle qui sert de support principal pour les questions sur l'évolution du format, l'avantage à domicile, le palmarès, et la plus grande partie de l'analyse sur la prédictibilité des résultats.

Colonne	Vient de	Ce qu'elle contient
home team / away team	matches (harmonisé)	Nom de pays canonique
home_score / away_score	matches	Buts marqués dans le match
Year / Round / Date / Host	matches	Contexte du match
home_elo / away_elo	elo (jointure)	Score Elo au 31/12 de l'année précédente
Teams / Champion	wc (jointure)	Contexte de l'édition



6.2 base_2022_ranking — la base complémentaire (édition 2022)

Cette base, limitée aux 64 matchs du Mondial 2022, associe à chaque match le rang et les points FIFA officiels des deux équipes. Elle sert surtout de point de comparaison : est-ce que le classement Elo (construit sur tout l'historique) et le classement FIFA officiel (construit sur une fenêtre de résultats plus récente) racontent à peu près la même histoire quand il s'agit de prédire un résultat ? Cette comparaison est développée dans les Parties 7 et 8.

6.3 Quelques vérifications avant de passer à l'analyse

Avant d'aller plus loin, nous avons fait quelques contrôles simples sur ces deux bases : pas de doublon sur la combinaison (équipes, date), des écarts de score et d'Elo qui restent dans des plages cohérentes, et une vérification à la main de quelques matchs pris au hasard pour s'assurer que les scores et les équipes correspondent bien à la réalité.

Nous avons aussi voulu vérifier que world_cup.csv et matches.csv racontent bien la même histoire, puisque ce sont deux fichiers différents qui décrivent en partie la même chose (l'un au niveau de l'édition, l'autre au niveau du match). Pour ça, nous avons recalculé nous-même, à partir des 964 lignes de matches, l'affluence moyenne et le nombre de matchs de chaque édition, pour les comparer aux colonnes AttendanceAvg et Matches déjà présentes dans world_cup.csv.



Ces deux courbes qui se superposent à la perfection donnent une bonne garantie : les deux fichiers ont été construits de façon cohérente entre eux, malgré leurs origines et leurs granularités différentes. C'est le genre de vérification croisée que nous referons avant de publier n'importe quelle analyse basée sur plusieurs sources .


PARTIE 7

Realiser une analyse exploratoire

Cette partie compare les grandes catégories de la base de travail (éditions, position à domicile, confédérations, niveau de force Elo) avant de formaliser les réponses en Partie 8. Nous en profitons aussi pour varier les types de graphiques utilisés (courbe, camembert, barres, boxplot, countplot, subplot, heatmap), chacun étant choisi parce qu'il correspond le mieux à la question posée à ce moment-là, pas juste pour varier les plaisirs.


7.1 Un tournoi qui a changé d'échelle

Le nombre d'équipes qualifiées est passé de 13 en 1930 à 32 depuis 1998, avec un palier à 24 équipes entre 1982 et 1994. Le nombre de matchs a suivi la même trajectoire, de 17-18 matchs lors des premières éditions à 64 depuis 1998.



Pour donner une idée plus intuitive du poids de chaque format dans l'histoire du tournoi, j'ai choisi ici un camembert plutôt qu'un graphique en barres : la question posée est « quelle part de l'histoire du Mondial chaque format représente-t-il? »


Répartition des 22 éditions selon le format du tournoi



La moitié des éditions jouées depuis 1930 (11 sur 22) l'ont été avec seulement 13 à 16 équipes : le format à 32 équipes qu'on connaît aujourd'hui, bien qu'il paraisse être la norme, ne couvre en réalité qu'un tiers de l'histoire de la compétition.

L'affluence moyenne, elle, ne suit pas une simple courbe croissante : elle atteint son maximum en 1994 (près de 69 000 spectateurs par match, un Mondial organisé aux États-Unis dans de très grands stades de football américain), puis se stabilise autour de 45 000 à 53 000 spectateurs par match sur les éditions les plus récentes.


Affluence moyenne par match selon l'édition



7.2 Domicile / extérieur : deux lectures possibles


Sur l'ensemble des 964 matchs, l'équipe citée en premier dans le tableau (« home_team ») marque en moyenne 1,78 but par match, contre 1,04 pour l'autre équipe.

Ce chiffre est à prendre avec des pincettes : la plupart des matchs de Coupe du Monde se jouent en terrain neutre, et l'ordre home/away dans le fichier reflète surtout l'ordre du tableau de compétition plutôt qu'un vrai avantage géographique. Une lecture plus juste consiste à ne regarder que les matchs où l'équipe « home » est réellement le pays organisateur du tournoi.



7.3 Le vrai avantage du pays hôte


En ne gardant que les 81 matchs où l'équipe à domicile est le pays organisateur, l'écart devient beaucoup plus net : 2,15 buts marqués en moyenne par le pays hôte contre 0,89 pour ses adversaires, et une victoire dans 71,6 % des cas.



7.4 Comparaison par confédération


Le classement FIFA d'octobre 2022 compte 211 sélections, réparties de façon inégale entre les six confédérations : l'UEFA (Europe, 55 sélections) et la CAF (Afrique, 54) représentent à elles seules plus de la moitié des équipes classées, contre seulement 10 pour la CONMEBOL (Amérique du Sud).

Ce chiffre est surtout à mettre en regard du nombre de pays membres de chaque confédération, pas de son niveau sportif : la CONMEBOL, la plus petite en nombre de membres, reste historiquement l'une des confédérations les plus performantes en Coupe du Monde (avec le Brésil et l'Argentine entre autre), ce qui montre que « nombre de sélections classées » et « niveau sportif » sont deux choses différentes.



7.5 La force sportive dans le temps


L'historique Elo permet de suivre la trajectoire de plusieurs grandes nations sur plus d'un siècle. Le Brésil dépasse l'Argentine, la France et l'Allemagne dès les années 1930 et garde cette avance jusqu'à dans les années 1950-60 ; l'Allemagne et la France ne rejoignent ce groupe de tête que plus tard, respectivement à partir des années 1950 et 1970.



Ce graphique montre aussi que même les plus grandes nations traversent des périodes de creux marquées. La France entre 1908 et 1950, par exemple, ce qui relativise l'idée d'une hiérarchie figée entre nations « fortes » et « faibles » dans l'histoire du football.

7.6 Trois façons de regarder la distribution des données

Plutôt que de décrire les distributions uniquement avec des chiffres, j'ai construit un subplot, c'est-à-dire une figure à plusieurs volets qui rassemble deux graphiques différents côte à côte pour pouvoir les comparer d'un coup d'œil. Chaque volet utilise le type de graphique le plus adapté à la question posée, ce qui permet aussi de montrer deux techniques différentes sans multiplier les figures séparées.




Le panneau A est un histogramme classique : il montre la forme de la distribution des buts marqués, avec un pic autour de 1 but et une décroissance progressive au-delà, cohérent avec les pourcentages détaillés plus loin.

Le panneau B est un boxplot (« boîte à moustaches ») appliqué à l'affluence par match. J'ai choisi ce type de graphique précisément parce qu'il permet de voir en un coup d'œil la médiane, la dispersion (la boîte couvre 50 % des matchs) et surtout les valeurs extrêmes, représentées par les points isolés au-dessus de la moustache supérieure. Treize matchs sortent ainsi du lot avec plus de 105 000 spectateurs : quatre matchs du Brésil au Maracanã en 1950, et plusieurs matchs du Mondial 1986 au Mexique joués dans l'immense stade Azteca. C'est exactement le genre de valeurs déjà repérées comme aberrantes-mais-réelles en Partie 3.4, et le boxplot permet de les visualiser directement plutôt que de seulement les citer dans un tableau.

Le nombre de buts marqués par équipe et par match suit une distribution assez classique pour ce sport : 0 but dans 28,6 % des cas, 1 but dans 33,1 %, 2 buts dans 21 %, puis une décroissance rapide au-delà (moins de 10 % des équipes marquent 3 buts ou plus). La moyenne se situe à 1,41 but avec un écart-type du même ordre (1,41),

7.7 Une vue d'ensemble : la carte de corrélation

Pour ne pas se limiter à examiner les relations entre variables une par une, j'ai construit une heatmap qui affiche en un seul visuel les corrélations entre les principales variables numériques du projet : les scores Elo des deux équipes, leur écart, les buts marqués de chaque côté, et l'affluence. C'est l'outil le plus efficace pour repérer d'un coup d'œil quelles paires de variables bougent ensemble, sans avoir à calculer chaque corrélation séparément.




Cette carte confirme et prolonge ce qui a été vu plus tôt : l'écart de score Elo (diff_elo) est fortement lié aux scores Elo pris séparément (0,70 avec home_elo, -0,70 avec away_elo) et modérément lié à l'écart de buts marqués (0,30 avec home_score, -0,26 avec away_score). Un résultat plus surprenant : le lien entre les scores Elo et l'affluence est faible mais positif (autour de 0,16 à 0,20), ce qui suggère que les matchs opposant des équipes plus fortes attirent un peu plus de monde, sans que ce soit un effet marqué. À l'inverse, l'affluence n'a presque aucun lien avec l'écart de buts (-0,02) : le public ne vient pas spécialement voir des matchs déséquilibrés, ni l'inverse.


Pour appuyer l'ensemble des constats présentés dans cette partie, je me suis limité à des méthodes statistiques simples mais adaptées au public visé : comparaisons de moyennes, calculs de pourcentages et de proportions, et coefficient de corrélation de Pearson. La droite affichée sur les nuages de points des Parties 7 et 8 vient d'une régression linéaire simple à une variable, utilisée pour visualiser la tendance générale, pas comme un modèle de prédiction à proprement parler.

7.8 Le palmarès sous toutes ses formes

Le classement des vainqueurs ne raconte qu'une partie de l'histoire. Une nation peut marquer durablement une compétition sans forcément la remporter souvent : c'est le cas de l'Argentine ou des Pays-Bas, très présents en finale sans toujours repartir avec le trophée. J'ai donc regardé aussi le nombre de finales disputées (gagnées ou perdues), et le nombre de fois où chaque nation a terminé 2e.




Le Brésil arrive logiquement en tête avec 7 finales disputées, mais l'Argentine, l'Italie et la RFA le suivent de près avec 6 finales chacune malgré un nombre de titres plus faible : ces nations ont souvent atteint le dernier match sans toujours le remporter.



Ce classement des « éternels seconds » met en avant les Pays-Bas, l'Argentine et la RFA avec 3 finales perdues chacune. Un cas curieux à noter : l'Argentine a disputé autant de finales gagnées que perdues (3 et 3), ce qui n'apparaît pas du tout si on ne regarde que le nombre de titres.

7.9 Les buteurs qui ont marqué l'histoire du tournoi


En dehors des nations, la Coupe du Monde est aussi une histoire de joueurs. La colonne TopScorrer de wc.csv donne le meilleur buteur de chaque édition avec son nombre de buts (au format « Nom - N buts ») : je l'ai extraite pour construire un classement de ces performances individuelles.




Le record appartient à Just Fontaine, qui a marqué 13 buts pour la seule édition 1958, un total que personne n'a approché depuis (le deuxième total le plus élevé, 11 buts par Sándor Kocsis en 1954, date de la même époque). Sur les 22 éditions, la moitié des meilleurs buteurs ont terminé avec 6 buts ou moins, ce qui montre que les très grosses performances individuelles comme celle de Fontaine restent des exceptions plutôt que la norme. Nul doute que notre Kylian Mbappé nationale battera tous les records dans cette édition 2026.

7.10 Qui a le plus (et le moins) joué la Coupe du Monde

Le nombre de matchs disputés par une nation dépend à la fois de son nombre de participations et de la longueur de son parcours à chaque fois (une équipe qui va en finale joue beaucoup plus de matchs qu'une équipe éliminée au premier tour).




Le Brésil (114 matchs) et l'Allemagne (112) dominent largement ce classement, ce qui n'est pas une surprise vu leur historique de qualifications quasi systématiques et leurs nombreux parcours profonds en phase finale.



À l'autre bout du classement, une quinzaine de nations sont à égalité avec seulement 3 matchs disputés (l'ordre entre elles sur ce graphique n'a donc pas de signification particulière) : ce sont des équipes qui ont participé une seule fois, dans un groupe à trois adversaires, sans se qualifier pour la suite. Le cas extrême est celui des Indes néerlandaises, avec un seul match joué dans toute l'histoire de la compétition : en 1938, le format prévoyait encore des éliminatoires directes dès le premier tour, et leur unique match s'est soldé par une élimination immédiate.

7.11 Une carte de toutes les participations

Pour visualiser d'un coup d'œil qui a participé à quelle édition, plutôt qu'une liste ou un chiffre agrégé, une heatmap pays x édition est l'outil le plus lisible : chaque ligne est un pays, chaque colonne une édition, et une case colorée signifie une qualification. Je me suis limité aux 25 nations les plus présentes pour garder un graphique lisible : avec 85 nations différentes ayant joué au moins un match depuis 1930, une heatmap complète serait illisible.



Cette carte fait ressortir un fait que les chiffres seuls ne montrent pas aussi bien : le Brésil est la seule nation présente à absolument toutes les éditions depuis 1930, sans une seule absence sur 92 ans, ce qui explique en partie pourquoi il domine aussi les classements de titres et de matchs joués. On voit aussi des trous très nets chez certaines grandes nations : l'Argentine manque les éditions 1938, 1950, 1954 et 1970, l'Italie est absente en 2018 et 2022, deux échecs qualificatifs qui ont marqué le football italien.

PARTIE 8

Réponses aux questions de la partie 1

Comment le format de la Coupe du Monde a évolué depuis 1930 ?


Le tournoi a changé d'échelle à trois reprises : 13 à 16 équipes entre 1930 et 1978, 24 équipes de 1982 à 1994, puis 32 équipes depuis 1998 (l'édition 2026 passera à 48 équipes, mais elle sort du cadre du fichier étudié ici, qui s'arrête en 2022). Le nombre de matchs a suivi, de 18 à 64. L'affluence moyenne, elle, ne progresse pas mécaniquement avec le nombre d'équipes : elle dépend surtout de la capacité des stades du pays hôte, comme le montre le pic de 1994 aux États-Unis.

Y a-t-il un avantage à jouer à domicile, et diffère-t-il pour le pays hôte ?

Oui, clairement, et l'ampleur de cet avantage dépend beaucoup de la façon dont on regarde la question. En se fiant seulement à la position dans le tableau (home_team), l'avantage semble modéré. Mais en ne gardant que les matchs où l'équipe est réellement le pays organisateur, l'avantage est bien plus marqué : 71,6 % de victoires, 18,5 % de nuls et seulement 9,9 % de défaites, avec un écart de but moyen de +1,26. Le pays hôte bénéficie donc d'un vrai avantage statistique, plus fort que ce que la seule position dans le tableau ne le suggère.

Quelles nations dominent le palmarès historique ?



Le Brésil est la nation la plus titrée avec 5 titres, devant l'Italie (4), l'Argentine et l'Allemagne de l'Ouest / réunifiée (3 chacune, en distinguant RFA et Allemagne réunifiée comme deux lignes), puis la France et l'Uruguay (2), et enfin l'Espagne, l'Angleterre et l'Allemagne réunifiée seule (1 chacun).



Seules 8 sélections différentes ont remporté la compétition en 22 éditions (en comptant RFA et Allemagne réunifiée à part), ce qui montre à quel point le titre reste concentré autour d'un petit noyau de nations, essentiellement sud-américaines et ouest-européennes.

La force sportive des équipes prédit-elle les résultats ?

La réponse est plutôt oui, mais avec des nuances, et c'est justement l'ajout du fichier elo.csv qui permet de répondre à cette question de façon beaucoup plus solide qu'avec le seul classement FIFA 2022. Sur les 948 matchs disposant d'un score Elo pour les deux équipes (1930-2022), et en ne comptant que les matchs à l'issue tranchée (hors match nul), l'équipe favorite au sens du score Elo l'emporte dans 71,0 % des cas. Le lien entre l'écart de score Elo et l'écart de buts marqués reste modéré (corrélation de 0,395), ce qui est plutôt attendu dans un sport où peu de buts se marquent et où la part de hasard reste importante à l'échelle d'un seul match.



PARTIE 9

Conclusions

9.1 Ce qu'il faut retenir

Ce projet a permis de transformer cinq sources de données assez différentes les unes des autres (une par édition, une par match, une photo de classement, un référentiel de codes pays, et un historique de force sportive sur 124 ans) en une base de travail unique et fiable, à partir de laquelle les cinq questions de départ ont trouvé une réponse chiffrée.

Trois résultats me semblent particulièrement à retenir. D'abord, l'avantage du pays hôte est bien réel (71,6 % de victoires), mais il est largement sous-estimé si on se contente de comparer les équipes « home » et « away » sans vérifier qui joue vraiment chez lui. Ensuite, le palmarès de la Coupe du Monde reste concentré sur un petit nombre de nations : 8 vainqueurs seulement en 22 éditions, dont 9 titres pour le Brésil et l'Italie réunis. Enfin, la force sportive mesurée avant le tournoi (Elo sur l'historique complet, ou classement FIFA pour 2022) prédit correctement l'issue d'environ 7 matchs sur 10 sur l'ensemble des 92 ans de compétition, ce qui laisse quand même une bonne place à la surprise, propre au football.

9.2 Les limites de ce travail

- Les pays disparus (URSS, RDA, Tchécoslovaquie, Yougoslavie...) ont volontairement été laissés de côté dans les jointures vers les classements actuels ; leurs matchs ne rentrent donc pas dans l'analyse de prédictibilité de la Partie 8, ce qui représente environ 1,7 % des matchs historiques.
- Le classement FIFA officiel n'a pu être utilisé que pour l'édition 2022, faute d'avoir un historique complet de ce classement pour les éditions précédentes — d'où le choix de s'appuyer surtout sur le score Elo pour l'analyse historique.
- Le lien entre force Elo et buts marqués, même s'il est réel, reste modéré : il ne faut pas y voir une prédiction fiable match par match, mais plutôt une tendance qui se vérifie sur un grand nombre de rencontres.
- Les colonnes très détaillées de matches.csv (buteurs, minute des cartons, détail des tirs au but) n'ont pas été exploitées ici et représentent une piste d'analyse complémentaire intéressante.

9.3 Pistes pour aller plus loin

- Exploiter les colonnes de buteurs pour reconstituer une base « buteur / minute » et étudier la dynamique des matchs (buts en fin de match, retournements de situation).
 - Construire un petit modèle prédictif (par exemple une régression logistique) prenant en compte l'écart Elo, le statut d'hôte et le tour de compétition, pour aller au-delà d'une lecture variable par variable.
 - Retrouver un historique complet du classement FIFA (et pas seulement un instantané) pour pouvoir comparer, édition par édition depuis sa création en 1992, le pouvoir prédictif du FIFA à celui de l'Elo sur une base vraiment comparable.
 - Garder et enrichir le dictionnaire de correspondance des noms de pays construit en Partie 4, pour pouvoir l'appliquer directement aux prochaines éditions du fichier, notamment celle de 2026 avec le passage à 48 équipes.
- Ce projet montre qu'une bonne part du travail d'un data analyst se joue avant même l'analyse : dans le contrôle qualité et la mise en cohérence des données. C'est ce travail, ici, qui a permis de faire passer la correspondance entre matches et elo à 98,3 %, et de transformer un cinquième fichier qu'on aurait pu négliger en la source la plus riche de tout le projet.

PARTIE B

RAPPORT DE VISUALISATION AVANCÉ

PARTIE 1

Modélisation des données: construction du schéma en étoile

1. Question de recherche et répartition du travail

Le projet est mené en groupe de quatre, autour d'une question principale :
Quels éléments permettent de prédire qu'une équipe a plus de chances de gagner en Coupe du Monde ?
Cette question a été déclinée en quatre sous-thématiques (vous remarquerez une évolution car 5 questions étaient posées au lancement de ce projet), chacune confiée à un membre du groupe :

N°	Sous-thématique	Question associée	Responsable
1	Force sportive avant tournoi	La force sportive d'une équipe avant le tournoi (classement Elo ou classement FIFA) permet-elle de prédire l'issue des matchs pendant la compétition ?	LP
2	Avantage du pays hôte	Le pays organisateur bénéficie-t-il d'un avantage compétitif ?	Amal
3	Répartition géographique du niveau	Comment se répartissent les 211 sélections du classement FIFA entre les 6 confédérations continentales ? Existe-t-il une partie du monde plus propice à l'émergence de prodiges du football ?	Julien
4	Valeur marchande de l'effectif	Peut-on prédire les performances d'une équipe à partir de la valeur marchande de son effectif ?	Melissa

Chaque sous-thématique s'appuie sur les mêmes sources de données nettoyées en commun (wc_clean, matches_long_clean, dim_team_clean, elo_clean, et teams_values_clean), afin de garantir la cohérence du modèle de données final et la possibilité de croiser les analyses entre elles dans Power BI.

2. Objectif

Avant d'importer les données dans Power BI, nous avons cherché à structurer nos sources selon un schéma en étoile (ou constellation), c'est-à-dire un modèle où des tables de faits (les mesures que l'on souhaite analyser) sont reliées directement à des tables de dimensions (les axes d'analyse), sans qu'aucune dimension ne pointe vers une autre dimension.

3. Constat de départ : cinq tables, cinq granularités différentes

Avant de construire quoi que ce soit, nous avons identifié le niveau de détail de chaque table, car un schéma en étoile ne peut fonctionner que si l'on sait précisément ce que représente une ligne dans chaque table.

Table brute	Une ligne représente	Nombre de lignes
<code>world_cup.csv</code>	une édition de Coupe du Monde	22
<code>matches_1930_2022.csv</code>	un match (deux équipes en colonnes)	964
<code>fifa_ranking_2022-10-06.csv</code>	une sélection nationale, au 6 octobre 2022 uniquement	211
<code>teams.csv</code>	une correspondance code pays ↔ nom pays	330
<code>elo.csv</code>	une sélection nationale, pour une année donnée	17 884
<code>teams_value.csv</code>	un pays, avec la valeur marchande de son effectif	149

Cette hétérogénéité de grain a fait apparaître trois difficultés qu'il fallait résoudre avant toute modélisation, et qui ont abouti à la construction des cinq tables finalement importées dans Power BI : `wc_clean`, `matches_long_clean`, `dim_team_clean`, `elo_clean` et `teams_values_clean`.

4. Difficulté n°1: une dimension à rôles multiples dans matches

La table `matches_1930_2022` comporte deux colonnes, `home_team` et `away_team`, qui pointent toutes les deux vers la même notion d'« équipe ». La table de faits ne pointe pas vers une clé unique, ce qui complique les relations dans Power BI.

Solution retenue : transformer cette table d'un format une ligne par match (deux équipes en colonnes) vers un format une ligne par équipe et par match. Chaque match génère ainsi deux lignes, une pour l'équipe à domicile, une pour l'équipe à l'extérieur. C'est cette transformation qui donne la table `matches_long_clean` : elle permet une relation simple et unique vers la dimension équipe, et sert de support à nos thématiques force sportive avant tournoi et avantage du pays hôte.

5. Difficulté n°2: une photo unique face à un historique


Le classement FIFA brut (`fifa_ranking_2022-10-06`) ne contenait qu'un instantané du classement à une date donnée (octobre 2022). Il ne permettait donc pas de répondre à la thématique (1), qui nécessite de connaître la force sportive d'une équipe au moment de chaque édition de la Coupe du Monde (par exemple le classement de l'Argentine en 1986). **Solution retenue** : utiliser la table `elo_clean`, qui contient un historique année par année, comme support de l'analyse de force sportive dans le temps. Le classement FIFA n'a servi que ponctuellement, pour construire la confédération de chaque équipe dans `dim_team_clean`, et non comme dimension temporelle dans le modèle final.

6. Difficulté n°3: le risque de schéma en flocon

Un risque de schéma en flocon apparaissait entre teams.csv (correspondance code ↔ nom de pays) et le classement FIFA (nom de pays → confédération) : si ces deux tables avaient été importées séparément dans Power BI et reliées l'une à l'autre, il aurait fallu deux sauts de relation pour qu'une table de faits (par exemple elo_clean) atteigne l'information de confédération.

Solution retenue : effectuer cette fusion en amont, directement en Python avec pandas, plutôt que dans Power Query. Les colonnes pays et confédération ont été calculées et intégrées via un dictionnaire de correspondance (code_vers_nom, conf_map), incluant la gestion des cas particuliers (renommages historiques de pays, correctif du code « NA » pour la Namibie mal interprété comme valeur manquante par pandas).

Cette fusion en amont a permis de construire une seule table de dimension équipe, dim_team_clean, qui contient en une seule ligne par équipe : le code, le nom et la confédération. Les tables brutes teams.csv et fifa_ranking_2022-10-06.csv ne sont donc plus nécessaires telles quelles dans le modèle final : elles n'ont servi qu'à la construction de dim_team_clean en amont.



7. Schéma en constellation final retenu


Le modèle importé dans Power BI comprend cinq tables :

- dim_team_clean (dimension) : une ligne par équipe, avec code, nom et confédération. Table pivot du modèle, partagée par les trois tables de faits.
- wc_clean (dimension), construite à partir de world_cup.csv : une ligne par édition de Coupe du Monde, avec l'année, le pays hôte, le nombre d'équipes, l'affluence et le champion.
- matches_long_clean (fait) : une ligne par équipe et par match (format long), reliée à dim_team_clean et à wc_clean. Support des thématiques (1) et (2).
- elo_clean (fait) : une ligne par équipe et par année, reliée à dim_team_clean. Support historique de la thématique (1) et base principale de la thématique (3).
- teams_values_clean (fait), construite à partir de teams_value.csv : une ligne par pays (149 lignes), reliée à dim_team_clean, avec la valeur marchande de l'effectif de chaque sélection. Support de la thématique (4).

Chaque table de faits pointe directement vers une dimension déjà consolidée, et aucune dimension ne pointe vers une autre dimension : le modèle respecte ainsi la définition d'un schéma en constellation.

7. Évolutivité du modèle

Le principal avantage de ce schéma s'est confirmé au moment d'intégrer la quatrième thématique : `teams_values_clean` n'a eu besoin que d'être reliée à `dim_team_clean`, sans aucune modification de la structure des autres tables. Malgré ses 149 lignes (contre 211 pour `dim_team_clean`, certaines sélections n'ayant pas de valeur marchande disponible dans la source), elle s'insère directement dans le modèle existant grâce à la clé pays déjà harmonisée en amont. C'est la preuve que le choix d'une dimension équipe centralisée et propre dès le départ, plutôt que des jointures ad hoc table par table, rend le modèle réellement évolutif.



PARTIE 2

Classification du problème

2.1. Quel type de problème de visualisation ce projet vise t'il à résoudre?

Le problème central n'est pas un manque de données mais la nécessité de croiser quatre angles d'analyse indépendants pour répondre à une question unique : quels sont les éléments qui permettent de prédire qu'une équipe a plus de chances de gagner qu'une autre ? Chaque membre du groupe a exploré un facteur explicatif différent — la force sportive avant tournoi (Laurent-Pierre), l'avantage du pays hôte (Amal), la répartition géographique des talents par confédération (Julien), et la valeur marchande de l'effectif (Melissa) — à partir des mêmes tables nettoyées en commun. Le problème de visualisation consiste donc à communiquer, pour chacun de ces quatre facteurs pris séparément, une réponse claire à la question « ce facteur a-t-il un pouvoir prédictif réel ? », tout en gardant une cohérence d'ensemble qui permette, in fine, de les comparer entre eux.

2.2 Objectifs de visualisation

Trois objectifs ont guidé la conception de ces rapports :

- Isoler l'effet de chaque facteur pour éviter de mélanger les explications : la force Elo, l'avantage du terrain, la géographie des talents et la valeur marchande sont quatre hypothèses distinctes, et chaque sous-partie du rapport doit permettre de juger l'une sans être polluée par les trois autres.
- Mettre en évidence des modèles clés plutôt que d'afficher des données brutes, propres à chaque sous-thématique.
- Soutenir la prise de décision analytique, ici la réponse à la question globale du groupe : parmi ces quatre facteurs, lesquels ont un vrai pouvoir prédictif, et lesquels sont davantage des idées reçues que les chiffres ne confirment pas ?

2.3 Critères de performance et métriques d'évaluation

Pour juger l'efficacité des rapports, deux axes ont été retenus : sa capacité à répondre à la problématique métier du groupe, et la qualité de sa conception visuelle. Ces deux axes sont complémentaires: un rapport peut être esthétiquement soigné sans aider à la décision, ou inversement contenir la bonne information sans être lisible, et c'est pour cette raison qu'ils sont évalués séparément plutôt que fondus en un seul critère générique.

- a) En quoi le tableau de bord répond à la problématique métier?

La problématique du groupe (quels sont les éléments qui permettent de prédire qu'une équipe a plus de chances de gagner qu'une autre?) est une question d'aide à la décision analytique plutôt qu'un simple exercice descriptif : il ne s'agit pas d'afficher des statistiques de Coupe du Monde, mais de permettre à l'utilisateur de juger, facteur par facteur, si une hypothèse tient ou non face aux chiffres. Le tableau de bord répond à cet objectif de trois façons :

- Il transforme une question complexe en quatre sous-questions vérifiables, chacune associée à un facteur explicatif (force sportive avant tournoi, avantage du pays hôte, répartition géographique des talents, valeur marchande de l'effectif). Cette décomposition est elle-même une aide à la compréhension : plutôt que de laisser l'utilisateur seul face à une question ouverte, chaque sous-partie du dashboard l'amène progressivement vers une réponse tranchée.
- Il confronte systématiquement une intuition à une donnée réelle. Dans ma propre sous-partie par exemple, l'intuition de départ (plus de sélections FIFA dans une confédération = plus de vivier de talents) est directement mise à l'épreuve par le nuage de points de la page 3 et la progression Elo de la page 4, qui montrent que ce n'est pas le cas pour la CONMEBOL. C'est ce mécanisme de confrontation hypothèse/donnée, reproduit dans chacune des quatre sous-parties, qui constitue la vraie valeur d'aide à la décision du dashboard : il ne se contente pas de montrer des chiffres, il permet de trancher.
- Il rend le résultat exploitable sans expertise technique. Le public visé (cf. Partie A, 1.1) est un public large, pas de data analysts. Chaque sous-partie se termine donc par une conclusion formulée en langage courant (par exemple le bloc "CONMEBOL — Confédération plus forte progression"), qui permet à n'importe quel utilisateur de repartir avec une réponse claire, même sans lire l'intégralité des visuels en détail.

• b) Qualité de conception des rapports

Plusieurs choix de design ont été faits pour que les rapports soit non seulement utile sur le fond, mais aussi efficace dans sa forme:

- **Pertinence des graphiques choisis** : chaque visuel a été sélectionné en fonction de la question qu'il devait trancher, et non par défaut. Un nuage de points a été utilisé quand il s'agissait de comparer deux variables entre elles (volume de sélections vs performance), un graphique en barres divergentes quand il s'agissait de montrer une progression positive ou négative par catégorie (progression Elo), et un donut uniquement pour représenter une répartition en proportion du tout (part de chaque confédération). Aucun graphique n'a été choisi pour son esthétique seule.
- **Cohérence des couleurs** : une palette de couleurs unique par confédération est réutilisée sur l'ensemble des pages (carte, donut, barres, nuage de points), ce qui permet à l'utilisateur de reconnaître immédiatement une confédération d'un visuel à l'autre sans avoir à relire une légende à chaque fois.
- **Accessibilité et daltonisme** : la palette retenue a été vérifiée pour rester distinguable en cas de daltonisme (notamment la confusion rouge/vert, la plus fréquente), en s'appuyant sur des teintes suffisamment contrastées en luminosité et pas uniquement en teinte. Le contraste entre le texte et le fond sombre a également été contrôlé, les libellés et valeurs étant systématiquement en blanc ou gris très clair sur fond anthracite, pour rester lisibles y compris pour les utilisateurs malvoyants.
- **Lisibilité générale et absence de surcharge visuelle** : chaque page se limite à trois ou quatre visuels maximum, avec des titres explicites, des légendes systématiques et les unités toujours précisées (% , points, nombre de matchs). Aucun graphique n'a été laissé sans titre ni sans axe légendé, y compris sur les visuels les plus simples comme les cartes KPI.
- **Hiérarchie visuelle et organisation de l'information** : une lecture en Z a été privilégiée sur la majorité des pages, de sorte que l'élément le plus important (le KPI de synthèse ou le titre de la page) soit toujours ce que l'œil rencontre en premier, et que l'élément le plus interprétatif (la conclusion ou le graphique le plus parlant) arrive en dernier, en bas à droite — une organisation qui suit la façon dont on raconte naturellement un raisonnement, du constat vers la conclusion.
- **Logique des filtres et interactions** : le slicer de confédération, disponible sur les pages qui le nécessitent, a été pensé comme un outil de comparaison plutôt que comme un simple filtre technique : il permet d'isoler une confédération pour la comparer mentalement aux autres, ce qui est particulièrement utile sur la page 3 où la densité d'information est la plus forte.

PARTIE 3

Conception et optimisation des rapports


3.1 Structure globale

Les rapports construits autour des quatre sous-thématiques du groupe, chacune développée par un membre différent mais suivant une logique de raisonnement commune : partir d'un constat chiffré simple, puis creuser jusqu'à une conclusion qui tranche sur le pouvoir prédictif du facteur étudié.

- Force sportive avant tournoi (Laurent-Pierre) : cette sous-partie confronte le classement Elo et le classement FIFA aux résultats réels des matchs, pour vérifier si l'équipe la mieux classée avant le tournoi est effectivement celle qui l'emporte.
- Avantage du pays hôte (Amal) : cette sous-partie compare les résultats du pays organisateur à ceux des autres équipes, pour quantifier si jouer à domicile influence réellement les chances de victoire.
- Répartition géographique du niveau par confédération (Julien) : cette sous-partie, dont le détail de conception est présenté ci-dessous, croise le volume de sélections par confédération avec leur performance sportive réelle, pour vérifier si une zone géographique est structurellement plus propice à l'émergence de talents.
- Valeur marchande de l'effectif (Melissa) : cette sous-partie met en regard la valeur marchande des effectifs et les performances des équipes en Coupe du Monde, pour évaluer si un effectif plus coûteux prédit un meilleur résultat sportif.

Ces quatre sous-parties suivent un fil conducteur dans la lecture des rapports, illustrée ici par le détail de la sous-partie sur les confédérations, que j'ai réalisé sur quatre pages Power BI (avec la création d'une table mesure affichée ci-dessous).


Voici un aperçu de la sous thématique sur les confédérations que j'ai pu produire :



Page 1 : premier aperçu de la répartition des confédérations d'un point de vue géographique, en terme de valeur marchande et de qualification du nombre de sélection par confédération en coupe du monde.



Page 2: Performance et efficacité, croisant matches_long_clean et dim_team_clean : elle confronte volume (Nb Sélections, Nb Participations CDM) et résultats sportifs (Taux de Victoire, Nb Titres Coupe du Monde), révélant que la CONMEBOL, avec seulement 10 sélections, affiche le meilleur taux de victoire.



Page 3: Évolution temporelle: elle confirme dans la durée le constat de la page 3 grâce au rapport entre le nombre de selection des confédérations et les résultats sportifs, et se conclut par une réponse explicite à la sous-question posée.



Ce même schéma en trois temps (cadrage, constat, explication, confirmation dans la durée) a vocation à structurer également les trois autres sous-parties du groupe, chacune adaptée à son propre facteur explicatif (par exemple, la sous-partie d'Amal compare les taux de victoire des matchs du pays organisateur face aux pays non organisateur).

3.2 Intégration des visualisations dans une interface cohérente

Pour que les quatre sous-parties du rapport ne ressemblent pas à quatre rapports indépendants, plusieurs éléments ont été gardés constants dans chacune : le même thème, la même logique, la même palette de couleurs réutilisée partout. Cette cohérence visuelle permet à un utilisateur qui a compris une sous-partie de naviguer plus facilement dans les trois autres sans réapprendre un nouveau code à chaque fois.

Sur la disposition de chaque page, une lecture en Z a été privilégiée dans l'ensemble du rapport : l'œil part en haut à gauche (les KPI ou le titre), balaie vers la droite (les graphiques de synthèse), puis redescend vers le bas à gauche avant de terminer en bas à droite.

3.3 Fonctionnalités interactives

Plusieurs slicers sont présents dans les rapports, et filtre l'ensemble des visuels de la page pour se concentrer sur une seule donnée à la fois (pays ou date par exemple). Ce principe de filtre doit permettre à l'utilisateur de croiser lui-même les différents facteurs.

Un drill-down, bouton de navigation entre les sous-parties, a été intégré. Ce bouton de navigation permet de circuler d'un facteur explicatif à l'autre sans dépendre des onglets Power BI, ce qui est particulièrement utile pour un rapport qui doit, in fine, mettre en regard quatre analyses différentes. Celui-ci est présent dans l'onglet “Sommaire” et permet du coup de présenter les 4 sous-parties.

Nous avons également inséré un bouton de retour au sommaire sur chaque page afin de simplifier la navigation dans notre fichier Power BI.



Sans filtre actif, la carte affiche les 211 sélections classées, le donut montre la répartition des six confédérations, et le graphique d'évolution du nombre d'équipes qualifiées superpose les six courbes.



En sélectionnant UEFA dans le slicer, la carte se recentre automatiquement sur l'Europe, la courbe d'évolution n'affiche plus que la trajectoire de l'UEFA, et les KPI (points moyens FIFA, valeur marchande moyenne) se recalculent pour ne refléter que cette confédération. Ce filtrage croisé permet à l'utilisateur d'isoler une zone géographique en un clic, sans changer de page ni relire une légende.



En sélectionnant l'édition 2014 puis « France » dans la liste des cinq plus grandes valeurs marchandes, toutes les cartes KPI se mettent à jour instantanément : étape atteinte (quart de finale), valeur de l'effectif (1 K M€), buts marqués (20), et le détail victoires/nuls/défaites (3/1/1).



En changeant simplement l'édition pour 2022 et l'équipe pour « Spain », le même jeu de cartes se recalcule pour afficher les résultats propres à l'Espagne cette année-là (8^e de finale, 4 K M€, 18 buts, 1/2/1). Ce croisement à deux dimensions (année × équipe) montre que le rapport ne se contente pas d'un filtre unique, mais permet une vraie exploration combinée des données.

3.4 Optimisations effectuées

L'organisation de chaque page a été pensée autour d'une règle simple : trois à quatre visuels maximum par page. Ce choix n'est pas arbitraire: au-delà de ce seuil, l'œil met plus de temps à identifier l'information pertinente, et le risque de diluer le message principal augmente fortement. Un problème d'autant plus sensible que le public visé n'est pas un public d'experts habitué à lire des rapports denses. Cette contrainte a directement influencé la conception. Ce principe, appliqué systématiquement sur les quatre sous-partie, a pour but de garantir un temps de lecture rapide et cohérent d'une sous-partie à l'autre.

3.5 Zoom sur les mesures Power BI

Au-delà de la centralisation des mesures évoquée en 3.5, certaines d'entre elles méritent d'être détaillées pour montrer que des indicateurs qui semblent simples au premier regard demandent en réalité une vraie logique DAX :

- Taux de Victoire / Taux de Nul / Taux de Défaite : construites avec DIVIDE plutôt qu'une division classique, pour éviter les erreurs d'affichage quand le dénominateur tombe à zéro (par exemple une confédération filtrée sur une période sans aucun match joué):

```

1 Taux de Victoire =
2 DIVIDE(
3     CALCULATE(
4         COUNTROWS(matches_long_clean),
5         matches_long_clean[resultat] = "victoire"
6     ),
7     COUNTROWS(matches_long_clean)
8 ) +0

```

- Nb Titres Coupe du Monde : combine SUMX et COALESCE pour additionner correctement les titres par équipe sans que les lignes sans titre (valeur NULL) ne cassent le calcul:

```

1 Nb Titres Coupe du Monde =
2 SUMX(
3     VALUES(dim_team_clean[pays]),
4     CALCULATE(
5         COUNTROWS(wc_clean),
6         FILTER(
7             wc_clean,
8             wc_clean[Champion] = dim_team_clean[pays]
9         )
10    )
11 )

```

- Confédération Plus Forte Progression : utilise CALCULATE et RANKX pour comparer automatiquement la progression Elo de chaque confédération entre le premier et le dernier point de la série temporelle, et faire ressortir directement le nom de la confédération en tête, sans que l'utilisateur ait à le lire lui-même dans le graphique:

```

1 Confédération Plus Forte Progression =
2 VAR TableProgression =
3     ADDCOLUMNS(
4         VALUES(dim_team_clean[confederation]),
5         "Progression", [Progression Elo]
6     )
7 VAR MaxProgression = MAXX(TableProgression, [Progression])
8 RETURN
9     MAXX(
10        FILTER(TableProgression, [Progression] = MaxProgression),
11        dim_team_clean[confederation]
12    )

```

- Rang dans Confédération : une mesure RANKX en contexte filtré, qui recalcule le classement d'une équipe uniquement parmi les membres de sa propre confédération plutôt que sur l'ensemble des 211 sélections:

```
1 Rang dans Confédération =  
2 VAR ConfedActuelle = SELECTEDVALUE(dim_team_clean[confederation])  
3 RETURN  
4     RANKX(  
5         FILTER(  
6             ALL(dim_team_clean[pays], dim_team_clean[confederation]),  
7             dim_team_clean[confederation] = ConfedActuelle  
8         ),  
9         CALCULATE(MIN(dim_team_clean[rank])),  
10        ,  
11        ASC  
12    )
```

PARTIE 4

Interprétation des résultats

4.1. Analyse des résultats et influence sur la conception

À l'échelle du projet, la question posée par le groupe: quels sont les éléments qui prédisent qu'une équipe a plus de chances de gagner qu'une autre? n'a de sens que si les quatre sous-parties peuvent être comparées entre elles. C'est cette exigence qui a motivé la construction d'un modèle de données unique et partagé (Partie 1), plutôt que quatre modèles indépendants : sans cette base commune, il aurait été impossible de dire, par exemple, si l'effet de la géographie (ma sous-partie) est plus ou moins déterminant que l'effet de la force Elo avant tournoi (sous-partie de Laurent-Pierre).

Sur ma propre sous-partie, la lecture croisée des pages a directement influencé la conception : le constat de la page 2 (l'UEFA et la CAF concentrent plus de la moitié des sélections classées) aurait pu, seul, laisser penser que l'Europe et l'Afrique sont les zones les plus « productrices » de talents. C'est en construisant le nuage de points de la page 3, qui confronte volume de sélections et résultats sportifs, que le déséquilibre est devenu visible : la CONMEBOL, avec seulement 10 sélections, se distingue par un taux de victoire et un ratio titres/sélections nettement supérieurs à son volume. Ce résultat a motivé l'ajout de la page 4, pour vérifier si ce constat était stable dans le temps — la Progression Elo confirme que la CONMEBOL est la seule confédération à réellement progresser sur la période étudiée.

Ce même principe — ne jamais se satisfaire d'un premier constat statique sans le confronter à une deuxième variable ou à la dimension temporelle — est la méthode qui doit guider les trois autres sous-parties, pour éviter par exemple de conclure trop vite qu'un classement FIFA élevé garantit la victoire, ou qu'un effectif coûteux garantit la performance, sans avoir croisé ces facteurs avec les résultats réels sur l'ensemble de la période étudiée.

4.2 Techniques de visualisation ayant permis une communication plus claire

Dans la sous-partie confédérations, deux choix se sont révélés particulièrement efficaces : le nuage de points de la page 3, qui montre en un seul visuel le décalage entre Nb Sélections et Nb Participations CDM, et le graphique en barres divergentes de Progression Elo (page 4), qui rend immédiatement visible quelles confédérations progressent et lesquelles reculent. Ces deux types de visuels partagent un même principe : ils ne se contentent pas d'afficher une valeur, ils rendent visible un écart entre ce qu'on pourrait attendre (plus de sélections = plus de performance) et ce que les chiffres montrent réellement.

Ce principe de visualisation de l'écart plutôt que de la valeur brute est transposable aux trois autres sous-thématiques du groupe : un nuage de points opposant classement Elo/FIFA et résultat réel du match (Laurent-Pierre), un graphique comparant le taux de victoire à domicile selon que l'équipe est ou non le pays organisateur (Amal), ou un nuage de points opposant valeur marchande et performance en Coupe du Monde (Melissa) permettraient chacun de révéler si l'intuition de départ (plus de force sportive, plus d'avantage du terrain, plus de valeur marchande = plus de victoires) se vérifie réellement dans les données, ou si elle doit être nuancée comme cela a été le cas pour la répartition géographique des talents.

À l'inverse, la carte géographique de ma page 2, bien qu'utile pour situer les confédérations dans l'espace, reste plus décorative qu'analytique : elle confirme une intuition déjà connue sans apporter d'information supplémentaire par rapport aux graphiques en barres à côté, un écueil à éviter dans les autres sous-parties si un visuel n'apporte pas plus qu'un tableau de chiffres ne le ferait déjà.

CONCLUSION

Difficultés rencontrées lors du projet

Le principal verrou scientifique

Le vrai verrou n'était pas technique au sens outil Power BI, mais conceptuel : il fallait faire tenir ensemble un modèle en constellation à cinq tables de granularités très différentes (une ligne par édition, une par match/équipe, une par équipe/année) tout en gardant une clé pays unique et fiable pour que les quatre sous-thématiques du groupe puissent se brancher dessus sans se marcher dessus.

Pour ma propre sous-partie, le verrou spécifique a été de distinguer volume de sélections classées et niveau sportif réel : le constat brut (UEFA et CAF représentent plus de la moitié des sélections FIFA) est trompeur tant qu'on ne le confronte pas à la performance réelle en Coupe du Monde, ce qui demandait de croiser `dim_team_clean` avec `matches_long_clean` et `elo_clean` plutôt que de s'arrêter à un simple donut de répartition.

Étant fan de football, il a fallu également se détacher des idées reçues que je pouvais avoir. Ma connaissance se limitant aux 30 dernières années maximum, l'analyse que nous avons pu faire nous a apporté d'autres informations importantes que je n'avais pas à ma portée, et donc une analyse beaucoup plus précise que ce que j'aurais pu faire sans ces données.

Prévisionnel

L'harmonisation des noms de pays (Partie 4-5 de la partie A) a pris beaucoup plus de temps que prévu : je pensais que le nettoyage serait terminé après le rendu 1, mais son adaptation au modèle en étoile de Power BI (construction de `dim_team_clean`, gestion du code « NA » de la Namibie, choix de laisser de côté les pays disparus comme l'URSS) a débordé sur la phase de conception des visuels, ce qui nous a fait parfois perdre du temps.

Jeux de données

Au-delà des cinq fichiers de départ, nous avons dû aller chercher d'autres sources CSV pour construire la sous-partie sur la valeur marchande des sélections (sous-thématique de Melissa), qui n'existait dans aucun des fichiers d'origine. À partir de ces fichiers trouvés en externe, il a fallu construire `teams_value.csv`, une table dédiée reliée à `dim_team_clean`, pour pouvoir analyser l'impact de la valeur marchande d'une sélection sur ses résultats en Coupe du Monde. Cette étape d'acquisition et de construction n'était pas prévue au départ et a demandé un travail de nettoyage supplémentaire, en plus de celui déjà réalisé sur les cinq fichiers initiaux.

Compétences techniques / théoriques

DAX a été la compétence la plus longue à acquérir dans ce projet : des mesures qui semblent simples en pandas (comme un taux de victoire) demandent une vraie compréhension du contexte de filtre et de la fonction `SUMX` pour être justes en Power BI. Les mesures Nb Titres Coupe du Monde et Confédération Plus Forte Progression ont nécessité plusieurs itérations avant d'obtenir un résultat correct.

Plus largement, la prise en main d'un nouvel outil comme Power BI n'a pas été simple. Il a fallu être curieux, cliquer un peu partout pour trouver le bon cheminement vers l'objectif souhaité. L'onglet « Visualisations » sur la droite de l'outil, en particulier, demande du temps pour l'apprivoiser : le grand nombre d'options disponibles n'aide pas à une prise en main rapide, et il faut souvent tâtonner pour trouver où cliquer afin d'obtenir le rendu voulu. Une fois cette prise en main acquise, en revanche, c'est un outil très plaisant à utiliser.

Sur ce point, les cours sur Python et sur Power BI proposés par Liora m'ont énormément aidé tout au long de ce projet, en me donnant les bases nécessaires pour ne pas partir de zéro sur ces deux outils.

Pertinence

La visualisation sous Python, réalisée en amont dans le rapport individuel, nous a permis de nous poser les bonnes questions concernant ce projet. C'est de cette étape que sont ressortis les quatre thèmes déclinés sous forme de question, qui nous ont permis de mieux cadrer notre sujet collectif.

Nous avons aussi dû revoir à plusieurs reprises notre approche dans l'organisation du document Power BI, afin de montrer le plus en détail possible le cheminement des fichiers bruts jusqu'au rendu final. Au départ, nous nous étions cantonnés à l'explication des seules données FIFA analysées, sans évoquer toute la phase de nettoyage et de transformation en Python en amont, une lacune qu'il a fallu corriger pour que le rapport raconte l'ensemble de la démarche, pas seulement son résultat.

La pertinence des visualisations dans le fichier Power BI nous a donné du fil à retordre. Il a fallu éviter les données redondantes d'une partie à une autre, et parfois même à l'intérieur d'une même sous-partie. Nous avons cherché à raconter une histoire, et le storytelling d'un fichier Power BI n'est pas si évident à construire : mettre en place une lecture en Z paraît simple sur le papier, mais l'est beaucoup moins dans la réalité. Jusqu'à la dernière minute (et encore à l'heure où j'écris ces lignes), j'ai continué à modifier la structure des rapports pour qu'elle soit la plus pertinente possible.

IT

Nous avons rencontré des difficultés avec Zoom : pendant plusieurs jours, le son ne fonctionnait plus pour personne sur l'outil. Nous avons donc dû nous appeler sur WhatsApp en parallèle, et n'utiliser Zoom que pour le partage d'écran, ce qui a compliqué l'organisation de nos points d'équipe pendant cette période.

Il a fallu également se mettre d'accord sur les arborescence de dossiers à utiliser afin que tout le monde puisse exécuter sans soucis le code Python, une fois toutes nos parties réunies.

De même, comme chacun modifiait le document Power BI à tour de rôle, il a fallu mettre en place une organisation pour ne laisser visible que la dernière version tout en gardant dans un dossier “old” les anciennes versions du document, au cas où un soucis informatique serait intervenu.

Autres

Travailler à quatre, à distance, sans se connaître au préalable, n'est pas toujours facile. Il faut composer avec l'emploi du temps de chacun, ainsi qu'avec l'implication variable des membres dans le projet. Nous avons par ailleurs décidé d'avancer chacun de notre côté sur notre sous-thématique respective, puis d'assembler le tout à la fin. Travailler sur un modèle de données partagé entre quatre personnes sans avoir encore les rendus des trois autres membres n'a donc pas toujours permis d'avancer aussi rapidement que je l'aurais souhaité.

Bilan

Ma contribution principale

J'ai porté la sous-thématique sur les confédérations, en construisant les trois pages de rapport associées ainsi qu'entre 30 et 40 mesures DAX (pour ma partie et l'introduction) centralisées dans une table de mesures dédiée et réutilisable par le reste du groupe. Au-delà de ma sous-partie, j'ai aussi contribué à la construction de `dim_team_clean`, la table pivot du modèle en constellation partagée par les trois tables de faits, ce qui a directement conditionné le travail des trois autres membres. Je me suis également occupé de modifier cette table afin d'obtenir une ligne par équipe plutôt qu'une ligne par match.

J'ai par ailleurs pris en charge le rendu final Power BI. Une fois toutes les sous-parties terminées, j'ai tout rassemblé dans un seul document, en recréant l'ensemble des mesures réalisées par les autres membres du groupe et en rapatriant toutes leurs visualisations dans le fichier commun. J'ai ensuite harmonisé le document pour obtenir un rendu agréable à la lecture :

- Création et harmonisation des titres des parties et onglets
- Mise en place de la charte graphique (thème, image de fond, couleurs adaptées aux daltoniens, ombrage pour chaque visualisation, harmonisation des typographies, harmonisation des titres et légende de chaque visualisation...)

Je pense (et j'espère) avoir été un moteur dans la réalisation de ce projet, en fixant entre autre les dates de nos réunions et en les animant comme je l'aurais fait dans mon poste actuel de manager d'équipe en relation client. Je me suis impliqué dans la relecture de chaque partie du projet (code Python, Power Query, Power BI) afin d'éviter les mauvaises surprises. A chaque avancée, je me suis permis de vérifier ce qui avait été fait pour m'assurer qu'on allait dans la bonne direction, et le cas échéant d'en discuter rapidement avec le reste du groupe pour corriger le tir.

Je tiens à souligner l'implication de Melissa et d'Amal, avec qui la synergie a très bien fonctionné : nous avons été impliqués tous les trois du début à la fin du projet. Les échanges avec Laurent-Pierre ont malheureusement été nettement plus compliqués avec l'ensemble de l'équipe.

Résultats obtenus face aux attendus de départ

Les objectifs fixés au départ du projet portaient sur plusieurs livrables : un rapport individuel en Python documentant la phase d'exploration et de nettoyage, un modèle de données structuré en schéma en étoile/constellation, une série de rapports Power BI répondant à la question globale du groupe, et un oral de soutenance. Sur les trois premiers points, les objectifs ont été atteints : le rapport Python a été livré avec l'ensemble de la démarche documentée, le modèle de données commun a bien été construit et partagé entre les quatre membres, et le tableau de bord Power BI assemblé permet de répondre, sous-partie par sous-partie, à la question posée.

Un challenge de taille reste toutefois encore à relever : réussir à faire tenir notre oral de soutenance en 20 minutes maximum, avec quatre sous-thématiques à présenter de façon cohérente et sans se répéter. Un exercice de synthèse qui s'annonce au moins aussi exigeant que la construction des rapports eux-même.

Pour finir...

Pistes d'amélioration

Il reste encore quelques améliorations possibles à l'heure actuelle, par exemple l'ajout d'infobulles personnalisées sur certaines visualisations, pour permettre à l'utilisateur d'obtenir un détail supplémentaire (comme le nom d'un pays) directement au survol, sans avoir à changer de page ou à croiser avec un tableau.

Nous aurions pu également intégrer d'autres critères impactant les résultats de matchs, comme par exemple:

- L'impact du calendrier et de la fatigue des joueurs
- Les décisions arbitrales et la VAR
- La formation des jeunes talents
- l'impact du réchauffement climatique

Contribution à la compréhension du problème

Nous nous sommes posés une question simple : *y a-t-il des éléments qui permettent de prédire qu'une équipe a plus de chances de gagner la Coupe du Monde ?*

À partir de ce questionnement, nous avons souhaité enquêter sur quatre éléments :

- Le rang FIFA et/ou les points Elo sont-ils des éléments qui permettent de prédire qu'une équipe peut gagner la Coupe du Monde ?
- Faire partie d'une confédération plutôt qu'une autre est-il un élément qui permet de prédire qu'une équipe peut gagner la Coupe du Monde ?
- La valeur marchande d'une sélection est-elle un élément qui permet de prédire qu'une équipe peut gagner la Coupe du Monde ?
- Être un pays hôte est-il un élément qui permet de prédire qu'une équipe peut gagner la Coupe du Monde ?

Notre travail nous a permis de répondre à ces questions :

- Plus une équipe est bien classée au rang FIFA, ou plus ses points Elo sont élevés, plus elle a de chances de gagner la Coupe du Monde.
- Depuis plusieurs années, la CONMEBOL est la confédération qui remporte le plus de titres, avec un ratio titres gagnés / nombre de sélections dans la confédération très impressionnant.
- Plus une sélection a une valeur marchande importante, plus ses joueurs sont de qualité, et plus elle a de chances de gagner la Coupe du Monde.
- Être un pays hôte augmente les chances de gagner la Coupe du Monde.

On peut donc répondre à la question initiale en affirmant qu'il existe bien des critères qui permettent d'augmenter les chances d'une équipe de gagner la Coupe du Monde et qu'ils sont cités ci-dessus.

Évidemment, d'autres pistes auraient pu permettre d'affiner ces résultats, par exemple :

- L'impact du calendrier et de la fatigue des joueurs joue-t-il un rôle important dans les résultats en sélection ?
- Les décisions arbitrales et la VAR ont-elles un impact non négligeable sur le classement FIFA ?
- Le passage à 48 équipes en 2026 va-t-il rebattre les cartes de la répartition par confédération ?
- La formation des jeunes talents est-elle la clef pour gagner la Coupe du Monde ?
- Quel est l'impact du réchauffement climatique sur l'organisation des futures Coupes du Monde ?

Pour terminer, ce projet m'a permis de me glisser dans la peau d'un data analyst, et ce qui en ressort est très positif. Cela m'a projeté sur le poste que je convoite. J'ai notamment appris à:

- Explorer, nettoyer, analyser des données issues de fichiers bruts
- Créer des colonnes ou de nouveaux dataframe afin de simplifier les analyses futures
- Réfléchir à des visualisations sur Pandas afin de choisir des axes d'analyses plus approfondis
- Créer un modèle de tables et formater correctement chaque données à l'intérieur de celles-ci avec Power Query
- Utiliser toutes les modalités de Power BI afin d'obtenir un rapport clair et compréhensible pour la cible visée.
- Présenter à l'oral un rapport complet en suivant un storytelling fluide et sensé.

Je remercie Liora de m'avoir donné les clefs pour pouvoir maîtriser mon futur poste.

